Obtener mejores modelos con pocos datos

Training set



Training set

Test set



Training set

Test set

Accuracy: 0.91



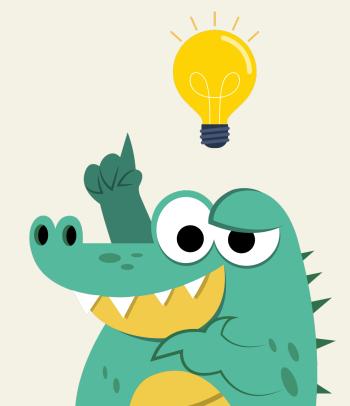
Training set



Training set

Training set

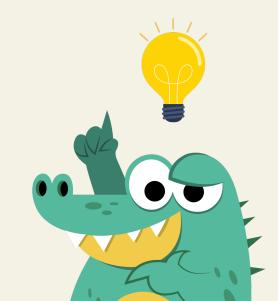
Test set



1st iteration Training set Training set Test set Acc: **0.98**



1st iterationTraining setTraining setTest setAcc: 0.982nd iterationTraining setTest setTraining setAcc: 0.92

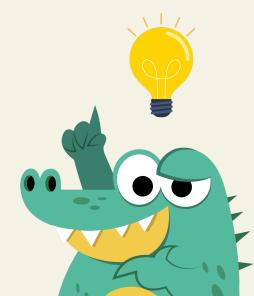


1st iteration	Training set	Training set	Test set	Acc: 0.98
2nd iteration	Training set	Test set	Training set	Acc: 0.92
3rd iteration	Test set	Training set	Training set	Acc: 0.96





Cross-validated accuracy: (0.98 + 0.92 + 0.96) / 3 = 0.95



Comúnmente usada cuando tenemos pocos datos, puesto que aprovecha al máximo lo poco que hay.

Aún recomendable con muchos datos si tu poder de cómputo lo permite.

Hay que tener especial cuidado cuando se trata de forecasting.

Búsqueda en grid

¿Cuáles son los mejores hiperparámetros?

Los modelos tienen varios hiperparámetros

¿Cómo le hacemos para encontrar los mejores?

¿Ejecución manual de experimentos?

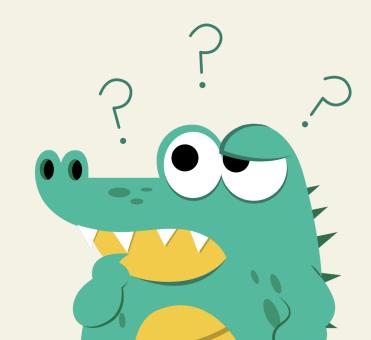


Los modelos tienen varios hiperparámetros

RandomForestClassifier

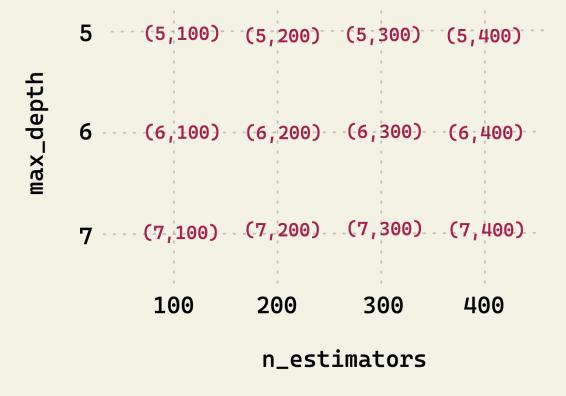
n_estimators: 100, 200, 300, 400

max_depth: 5, 6, 7



Grid search

```
n_estimators: 100, 200, 300, 400 | max_depth: 5, 6, 7
```





Grid search

Ventaja

 Espacio de búsqueda comprensivo – prueba todas las combinaciones que le demos.

Desventaja

- La complejidad crece con cada dimension – es exponencial
- Está limitada a las combinaciones que nosotros especificamos

Otras, mejores, opciones: Random search y optimización bayesiana